

Predictor Climático

Chilpancingo, Guerrero

Sistema de Predicción Meteorológica con Machine Learning

Alumno: Josué Emanuel Díaz Rodríguez

Materia: Inteligencia Artificial

Institución: Instituto Tecnológico de Chilpancingo

Fecha: Mayo 2025

1. Introducción

El presente proyecto desarrolla un sistema de predicción meteorológica para la ciudad de Chilpancingo, Guerrero, aplicando técnicas de machine learning sobre series temporales de datos climáticos. La motivación principal es que la mayoría de los modelos de pronóstico existentes operan a escala nacional y no capturan adecuadamente el comportamiento local del clima en la región montañosa de Guerrero, cuya altitud de aproximadamente 1,350 msnm genera condiciones particulares.

El sistema toma datos históricos diarios de variables meteorológicas, los transforma en un problema de regresión supervisada mediante ingeniería de features, entrena y compara tres modelos de ML, y genera un pronóstico a 30 días con un semáforo de alerta por precipitación.

2. Objetivos

2.1 Objetivo General

Diseñar e implementar un modelo predictivo capaz de pronosticar la temperatura media y la precipitación diaria en Chilpancingo, Guerrero, con un horizonte de 30 días, usando algoritmos de aprendizaje automático entrenados sobre datos históricos.

2.2 Objetivos Específicos

- Construir un dataset representativo del clima local calibrado con parámetros del SMN.
- Aplicar ingeniería de features (lags, rolling statistics, codificación cíclica) para transformar la serie temporal.
- Comparar el desempeño de Random Forest, Gradient Boosting y Ridge Regression.
- Evaluar los modelos con métricas MAE, RMSE y R^2 .
- Generar un pronóstico rodante (rolling forecast) a 30 días con clasificación de riesgo.
- Visualizar los resultados mediante gráficas de análisis exploratorio y comparación de modelos.

3. Dataset

3.1 Fuente y Parámetros Climáticos

Los datos fueron generados sintéticamente con distribuciones estadísticas calibradas a partir de los registros históricos del Servicio Meteorológico Nacional (SMN) para la estación de Chilpancingo. El periodo comprende del 1 de enero de 2018 al 31 de diciembre de 2024, resultando en 2,557 registros diarios.

temp_media	Temperatura promedio del día	°C
temp_maxima	Temperatura máxima registrada	°C
temp_minima	Temperatura mínima registrada	°C
precipitacion_mm	Lluvia acumulada en el día	mm
humedad_relativa	Porcentaje de humedad del aire	%
velocidad_viento	Velocidad del viento	km/h
presion_hpa	Presión atmosférica	hPa
nubosidad_oktas	Cobertura de nubes (escala 0-8)	oktas

3.2 Características Climáticas de Chilpancingo

- Altitud: ~1,350 msnm
- Tipo de clima: Semicálido subhúmedo (Aw según clasificación de Köppen)
- Temperatura media anual: ~21°C
- Temporada de lluvias: mayo a octubre (concentra más del 85% de la precipitación anual)
- Precipitación anual promedio: 900-1,100 mm

4. Metodología

4.1 Pipeline General

El sistema sigue un flujo completamente automatizado de seis etapas: (1) ingesta del dataset, (2) pipeline ETL con filtrado y anonimización, (3) ingeniería de variables temporales, (4) entrenamiento de modelos con arquitectura dual (global + regionales), (5) forecast rolling a 30 días, y (6) visualización en dashboard con semáforo epidemiológico.

4.2 Ingeniería de Features

La serie temporal unidimensional se transforma en un problema de regresión supervisada estándar mediante las siguientes variables derivadas:

Lags (rezagos)	lag_1, lag_2, lag_3, lag_7, lag_14	Valores exactos de días anteriores
Media móvil	rolling_mean_7d, rolling_mean_14d	Tendencia reciente
Desv. estándar móvil	rolling_std_7d	Captura de volatilidad
Máximo / mínimo móvil	rolling_max_7d, rolling_min_7d	Detección de picos extremos
Cíclicas temporales	mes_sin, mes_cos, dia_sin, dia_cos	Estacionalidad sin discontinuidad
Variables clima	presion_lag1, humedad_lag1, precip_lag1	Predictores complementarios

La codificación cíclica del mes y del día del año mediante seno y coseno garantiza que el modelo entienda la continuidad entre diciembre y enero, evitando la discontinuidad que generaría usar números enteros directamente.

4.3 División del Dataset

Se emplea una división temporal estricta para evitar data leakage (filtración de información futura al conjunto de entrenamiento):

- **Entrenamiento (80%):** datos de 2018 a finales de 2023 — 2,034 días
- **Validación (20%):** datos del año 2024 — 509 días

No se usa división aleatoria porque en series temporales el orden cronológico es fundamental para la integridad de la evaluación.

5. Modelos de Machine Learning

Se entrenaron y compararon tres algoritmos con características complementarias:

Random Forest (principal)	Bagging con árboles en paralelo	Robusto ante ruido, no asume distribución	Modelo principal
Gradient Boosting	Árboles secuenciales correctivos	Alta precisión en patrones complejos	Alta capacidad
Ridge Regression	Regresión lineal con regular. L2	Simplicidad e interpretabilidad	Línea base

5.1 Hiperparámetros del Modelo Principal (Random Forest)

```
RandomForestRegressor(  
n_estimators = 200, # número de árboles  
max_depth = 12, # profundidad máxima  
min_samples_split = 5,  
min_samples_leaf = 2,  
random_state = 42,  
n_jobs = -1 # usar todos los núcleos  
)
```

6. Métricas de Evaluación

Se utilizaron tres métricas estándar para evaluar el desempeño de cada modelo:

MAE — Error Absoluto Medio

Promedio de los errores absolutos. Interpretable directamente en las unidades de la variable (°C para temperatura, mm para precipitación). Un MAE de 1.79°C significa que en promedio la predicción se aleja 1.79 grados del valor real.

RMSE — Raíz del Error Cuadrático Medio

Penaliza proporcionalmente más los errores grandes. Útil para detectar si el modelo tiene predicciones ocasionalmente muy malas.

R² — Coeficiente de Determinación

Porcentaje de varianza explicado por el modelo. $R^2=1.0$ indica predicción perfecta; $R^2=0$ significa que el modelo no aporta más que predecir siempre el promedio histórico.

7. Resultados Obtenidos

7.1 Predicción de Temperatura Media

	MAE	RMSE	R²
Random Forest	1.79	2.23	0.32
Gradient Boosting	1.85	2.31	0.27
Ridge Regression	1.84	2.29	0.28

7.2 Predicción de Precipitación

	MAE	RMSE	R²
Random Forest	6.39	12.42	0.18
Gradient Boosting	6.52	12.85	0.12

El Random Forest fue el mejor modelo en ambas variables. Los valores de R^2 para precipitación son relativamente bajos (~0.18), lo cual es un resultado esperado y coherente con la naturaleza estocástica de la lluvia: predecir precipitación exacta con solo datos históricos locales es uno de los problemas más difíciles en meteorología computacional.

8. Pronóstico a 30 Días (Rolling Forecast)

El pronóstico iterativo funciona de la siguiente manera: se toman los últimos datos reales disponibles como historial base, se predice el día siguiente, esa predicción se agrega al historial, y el proceso se repite por 30 ciclos.


Cada día predicho incluye una clasificación de alerta por precipitación:

- ■ **Alerta Baja:** precipitación esperada menor a 5 mm
- ■ **Alerta Media:** entre 5 y 20 mm
- ■ **Alerta Alta:** más de 20 mm — riesgo de tormenta


Importante: la confiabilidad del pronóstico decae progresivamente con cada día adicional, ya que el error se acumula en el proceso iterativo. La ventana de predicción con mayor confianza es de 7 a 10 días.

9. Gráficas Generadas

Serie histórica de temperatura y precipitación (2018-2024)




Patrón mensual — boxplots de temperatura y precipitación promedio




Comparación de MAE, RMSE y R² entre los tres modelos


Comparacion de Modelos – Prediccion de Temperatura




Real vs predicho — últimos 90 días del conjunto de prueba



Top 15 variables más importantes según el Random Forest




Mapa de calor de correlación entre variables climáticas



Pronóstico a 30 días — temperatura y precipitación

Pronostico Climatico — Chilpancingo, Guerrero (30 dias)



10. Stack Tecnológico

Lenguaje	Python	3.10+	Lenguaje base del proyecto
Datos	Pandas	2.0	Manipulación del dataset
Cálculo numérico	NumPy	1.24	Operaciones matriciales
Machine Learning	scikit-learn	1.3	Modelos RF, GB, Ridge
Visualización	Matplotlib	3.7	Todas las gráficas
Visualización	Seaborn	0.12	Mapa de calor correlación
PDF	ReportLab	4.0	Generación de este documento

11. Instrucciones de Ejecución

1. Instalar dependencias:

```
pip install -r requirements.txt
```

2. Ejecutar el sistema completo:

```
python predictor_clima.py
```

3. Solo generar/explorar el dataset:

```
python generar_dataset.py
```

Al finalizar se habrán creado los siguientes archivos:

- **datos/chilpancingo_clima_2018_2024.csv** — dataset histórico completo
- **datos/pronostico_30dias.csv** — pronóstico con alertas de precipitación
- **graficas/** — carpeta con las 7 gráficas de análisis y resultados

12. Limitaciones y Trabajo Futuro

12.1 Limitaciones Actuales

- Los datos son sintéticos. Idealmente se utilizarían los CSVs descargados directamente del portal de datos abiertos del SMN para la estación de Chilpancingo.
- La precipitación es inherentemente difícil de predecir con solo datos de series de tiempo. Modelos más avanzados integran presión de sistemas atmosféricos, imágenes satelitales o reanálisis climáticos (ERA5, MERRA-2).

- El forecast rolling acumula error iterativamente, reduciendo la confiabilidad después de 7-10 días proyectados.
- No se incorporan variables externas como el índice ENSO (El Niño/La Niña), que tiene un impacto conocido sobre las lluvias en Guerrero.

12.2 Mejoras Propuestas

- Integrar datos reales descargados del SMN o de CONAGUA vía API.
- Agregar el índice ENSO como feature exógena al modelo.
- Explorar redes neuronales recurrentes (LSTM) específicas para series temporales.
- Implementar intervalos de confianza en las predicciones para cuantificar incertidumbre.
- Escalar el sistema a múltiples municipios de Guerrero con modelos regionales independientes.

13. Referencias

- [1] Servicio Meteorológico Nacional (SMN). smn.conagua.gob.mx
- [2] Köppen, W. (1936). Das geographische System der Klimate. Handbuch der Klimatologie.
- [3] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
- [4] Friedman, J.H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics.
- [5] Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825-2830.
- [6] Hoerl, A.E. & Kennard, R.W. (1970). Ridge Regression. Technometrics, 12(1), 55-67.
- [7] Datos abiertos SMN: <https://smn.conagua.gob.mx/es/climatologia/informacion-climatologica>